

Vấn đề thường gặp với dữ liệu giá theo phút

Dữ liệu giá theo phút có nhiều vấn đề đặc thù. Trước hết, **dữ liệu không đầy đủ** là hiện tượng phổ biến: có thể thiếu các timestamp nếu phiên giao dịch không có lệnh khớp (gap) hoặc do lỗi dữ liệu (feed dropout). Ví dụ, **holiday** hoặc sự cố kỹ thuật có thể khiến một số phút trống, và cổ phiếu thanh khoản kém thì dễ bị nhiều khoảng trống hơn ¹. Thứ hai, thị trường thường có **vùng thời gian biến động mạnh** (giờ mở cửa, đóng cửa) và trầm lắng (giờ nghỉ trưa), dẫn đến **mùa vụ trong ngày (intraday seasonality)**: giá dao động và độ biến động thay đổi theo khung giờ trong ngày ². Thứ ba, giao dịch cao tần có **nhiều cơ cấu thị trường** (market microstructure noise) như nhiều bid-ask bounce, khối lượng thấp, độ rời rạc về giá. Các nghiên cứu cho thấy cổ phiếu thanh khoản cao có tỉ lệ “nhiều/tín hiệu” thấp hơn; ngược lại, cổ phiếu ít giao dịch có mức nhiễu lớn hơn. Nhiễu này làm tăng biến động ngẫu nhiên trên chuỗi giá.

Nhìn chung, dữ liệu phút có tỷ lệ “tín hiệu/tạp âm” **thấp** hơn dữ liệu ngày, và các cú sốc (giá nhảy) có thể bị nhầm là lỗi. Khi test cointegration, nếu không xử lý, những vấn đề này sẽ tạo sai sót (e.g. sóng siêu ngẫu nhiên phá bỏ tính $I(1)$ của chuỗi).

Các lỗi dữ liệu: thiếu timestamp, không đồng bộ, chênh lệch giờ, microstructure

Thiếu timestamp (missing data) xảy ra khi không có lệnh khớp tại một phút cố định. Đây có thể do ngày nghỉ, sự cố feed, hoặc thanh khoản thấp khiến không có giao dịch trong khoảng. Theo BlueChipAlgos (2025), những nguyên nhân thường là *lỗi feed dữ liệu, ngày lễ, hoặc thanh khoản thấp* ¹. Ví dụ, nếu chỉ sử dụng dữ liệu trao đổi duy nhất, thị trường Mỹ nghỉ lễ thì dữ liệu sẽ *không* có giá.

Không đồng bộ (asynchronous trading) đề cập đến trường hợp hai tài sản giao dịch ở thời điểm khác nhau. Nếu dùng giá khớp gần nhất, có thể đánh đồng hai chuỗi không cùng cột thời gian. Các phương pháp phổ biến là thiết lập lưới thời gian cố định (ví dụ mỗi phút) và luôn lấy **giá gần nhất trước đó** làm giá tại timestamp đó. Phương pháp “fixed-interval sampling” được đề cập trong khảo sát của Sun et al. (2023) là chọn mốc đều (mỗi phút) và dùng giá đóng (giá cuối) của phút trước đó ³. Một cách khác trong nghiên cứu hồi quy tài chính (refresh-time sampling) là mỗi khi cả hai chuỗi có giao dịch mới, cập nhật cả hai chuỗi tại thời điểm muộn nhất.

Chênh lệch giờ giao dịch (market hours mismatch): Nhiều khi hai tài sản trong cặp không giao dịch đồng bộ về khung giờ. Ví dụ: một tài sản giao dịch 24 giờ (tiền điện tử), một tài sản chỉ từ 9:30-16:00 (chứng khoán Mỹ); hoặc giao dịch ở sàn khác múi giờ. Theo BlueChipAlgos, *khác biệt múi giờ* khi gộp dữ liệu từ vùng khác nhau sẽ sinh ra missing values ⁴. Để xử lý, thường áp dụng *overlap trading hours*: chỉ xét khoảng thời gian cả hai cùng mở cửa, hoặc lấp đầy giá theo cách carry-forward.

Nhiều cơ cấu (microstructure noise): Dữ liệu giao dịch phút vẫn chứa nhiễu do khớp lệnh. Ví dụ, hiện tượng “bid-ask bounce” (giá mua/giá bán không đổi nhưng giá giao dịch nhảy lên xuống) làm dữ liệu giá nhấp nhô mà không phản ánh xu hướng thực. Blog về dữ liệu cao tần khuyến nghị nên cẩn thận với những giao dịch cực nhỏ/volume thấp, vì thường coi đó là **nhiều** và lọc bỏ ⁵ (mặc dù đây là ví dụ tick, ý tương tự

áp dụng cho phút). Tổng quát, **nhiều sẽ tạo ra sai sót đơn vị-roots** trong ADF và làm suy giảm hiệu quả ước lượng hedge ratio.

Giá thô (raw) và giá log

Phương án **chuyển sang log** thường được khuyến cáo. Khi dùng giá log, mối quan hệ cointegration trở thành tuyến tính theo log (tức là tỉ lệ giá ổn định thay vì chênh lệch tuyệt đối). Nhiều ứng dụng và tài liệu pairs trading lấy log price trước khi test: ví dụ việc đưa phương trình cointegration vào log (Eqn. 11 trong Miao 2014) chỉ chính xác nếu log-prices là cointegrated và residual stationarity. Ngoài ra, log-transform giúp giảm phân phối lệch (skewed distribution) và làm tăng tính “xấp xỉ tuyến tính” của xu hướng dài hạn.

Tuy nhiên, **nên kiểm tra I(1)**: nếu giá thô có xu hướng nhân tạo (vd. lãi suất rủi ro không đổi), log có thể xử lý một phần. Song nếu dữ liệu đã ở mức biến thiên tuyến tính, việc log có thể không cần thiết. Trong `statsmodels` và nhiều thư viện, không yêu cầu phải log nhưng thường là **thói quen** trong tài chính để so sánh quy mô tương đối. Nhìn chung, **giải quyết mâu thuẫn**: nếu cointegration về tỷ lệ (ví dụ, $A = 2B$), log làm cointegrating vector trở thành hằng số; còn nếu quan tâm đến chênh lệch tuyệt đối nhỏ, có thể không log. Với đa số cặp chứng khoán, log prices (hay returns) là lựa chọn an toàn hơn.

Resampling và thời gian lấy mẫu

Tiếp theo, cần quyết định *tần suất* dữ liệu trước khi test. Nếu đã có dữ liệu minute đều (1 phút), thường giữ nguyên. Tuy nhiên, **nếu dữ liệu thô (ticks)** thì cần gom về minute hoặc 5-phút, để giảm nhiễu và cho phép lấy mẫu đồng bộ. Trong một số trường hợp, dữ liệu minute vẫn có khoảng trống – có thể *resample* theo lưới thời gian cố định. Ví dụ: tạo cột thời gian mỗi phút trong khung giao dịch và dùng forward-fill (hoặc cách khác) để lấp giá bị thiếu.

Trường hợp nên **nén (aggregate)**: nếu dữ liệu quá nhiều (ví dụ vi sóng chớp nhoáng) hoặc khối lượng quá thấp, ta có thể tụt xuống tần suất lớn hơn (5 hoặc 10 phút). Việc này giảm độ biến thiên giả tạo nhưng cũng làm mất bớt dữ liệu. Quyết định tùy thuộc yêu cầu nghiệm thu: cointegration test cần chiều dài đủ lớn (đủ quan sát), nên không nên mất quá nhiều mẫu. Đa số bài toán pairs sẽ giữ 1-phút nếu sample đủ lớn.

Trong khảo sát [2], việc *lấy mẫu đều* (uniform sampling) là cách phổ biến: lấy mỗi phút, sử dụng giá khớp cuối (last-tick) trước thời điểm đó ³. Cách này dễ triển khai nhưng có thể làm sai lệch thời điểm thực giao dịch. Một cách cải tiến là dùng thuật toán refresh-time để đồng bộ cả hai chuỗi (xem [2]). Trong bài toán 500 cặp, ít nhất cần chọn một quy ước nhất quán (ví dụ: cứ lấy giá đóng mỗi phút và dùng forward-fill để lấp giá thiếu).

Căn chỉnh hai chuỗi trước khi test

Trước khi chạy cointegration, phải **đảm bảo hai chuỗi giá có cùng khung thời gian**. Cụ thể: reindex hai chuỗi về một `DatetimeIndex` chung (ví dụ, mỗi phút giao dịch) và rồi xử lý giá khuyết. Thông thường, ta chỉ thử nghiệm trên phần dữ liệu mà cả hai đều có giá (inner-join). Có hai cách chính để align:

- **Last-tick interpolation**: với mỗi phút, lấy giá cuối cùng “trước hoặc đúng vào” phút đó. Ví dụ, dùng `.resample('1T').ffill()` trong Pandas để làm giá bù.
- **Pairwise-refresh**: mỗi khi một trong hai chuỗi có giao dịch mới, cộng đồng (common) thời gian cập nhật giá cả hai. Cách này đảm bảo không bỏ sót giao dịch mới nhưng phức tạp hơn.

Quan trọng: **loại bỏ tất cả các phút mà thiếu giá của bất kỳ chuỗi nào** (thay vì giả bộ fill thêm), vì ADF trên residual đòi hỏi không có lỗ hổng. Nếu một chuỗi thiếu giá ở phút đó, tốt nhất là *bỏ cặp phút đó* khỏi test (inner join trên index). Việc align này tránh việc test với hai chuỗi “nghĩa là” ở các thời điểm khác nhau.

Các quy tắc làm sạch dữ liệu và loại trừ tài sản

Trước khi scan 500 cặp, cần **loọc bỏ lỗi rõ ràng**:

- **Giá ≤ 0 hoặc NA**: Loại bỏ hoặc không dùng phút có giá âm, bằng 0 hoặc thiếu. Dữ liệu giao dịch bình thường không bao giờ có giá âm/0 .
- **Thiếu dữ liệu quá nhiều**: Nếu một mã có hơn X% thời gian (ví dụ >10%) không có giao dịch (missing), cân nhắc loại hẳn khỏi universe. Số mẫu lịch (T) nên đủ lớn để ADF có sức mạnh.
- **Biến động bất thường**: Dò tìm outlier theo biên độ lặp lại (ví dụ so với CI lần trong ngày như Brownlees & Gallo). Nếu có vài thanh giá bất nhảy quá mức so với xu hướng, nên loại (ví dụ dùng độ lệch chuẩn vượt ngưỡng). Tuy nhiên không nên quá “thiên kiến an toàn” (tránh loại giá nhảy thật).
- **Thanh khoản thấp**: Những tài sản hiếm giao dịch (rất nhiều phút không có lệnh) thường gây nhiễu. Các nghiên cứu khuyên loại bỏ hoặc ít nhất **thống kê cẩn thận** các cặp có một thành phần quá “yếu” (noise hơn là tín hiệu).
- **Thời gian giao dịch không rõ**: Nếu một chuỗi có khung giờ rất khác (ví dụ hợp đồng phái sinh ngày hôm trước đêm trước), tốt nhất chỉ lấy phần overlap.

Nói chung, ưu tiên **loại bỏ giá bất thường nhưng giữ tối đa dữ liệu thực**. Ví dụ, không xóa mọi ngày mà giá giật (như kiểu granger spurious regression), mà chỉ xóa ô nhỏ. Các quy tắc trình bày trong phần tick data (như thỏa thuận) có thể áp dụng tương tự: bỏ giá 0/âm, bỏ khoảng cách lớn (gaps) nếu nghi ngờ, và bỏ những tick đặc biệt (outlier) không thể giải thích.

Dấu hiệu loại trừ toàn bộ tài sản:

- Tài sản **hầu như không giao dịch** (hầu hết phút là lấp đầy giá cũ hoặc NA), nghĩa là chuỗi hầu như không thay đổi. Giả sử biến đổi = 0 suốt ($I(0)$ thực ra), test cointegration vô nghĩa (vì ta muốn $I(1)$ ban đầu). Loại nó ra.
- Tài sản **quá nhiều**: ví dụ giá liên tục nhảy sàn/trần hoặc chớp nhoáng mà không có xu hướng. Điều này có thể biểu hiện bằng p-value ADF đơn loạt cao hoặc spread không hồi quy tốt.
- Khung giờ bất thường: nếu đồng hồ giao dịch lệch nhiều, khả năng align chính xác thấp.

Phần lớn bài toán pairs yêu cầu mỗi chuỗi phải có đủ “information” ($I(1)$) và không chứa quá nhiều dữ liệu giả tạo. Những tài sản trên không thỏa mãn này nên bị loại ngay từ đầu.

Trade-off giữa làm sạch nhanh và quá mức

Làm sạch dữ liệu là một cân nhắc tinh tế: loại **quá nhiều** có thể loại luôn tín hiệu thật (đặc biệt các cú nhảy giá lớn, nếu là cú sốc thật), dẫn đến *thiếu dữ liệu và sai lệch mẫu*. Ngược lại, làm sạch **quá ít** thì tập dữ liệu còn nhiều nhiễu, khiến kết quả cointegration test bị sai lệch (ví dụ p-value giả tạo do outlier hoặc dữ liệu không đồng bộ). Vì vậy, nên cố gắng **tự động hóa các quy tắc cơ bản** (như ở trên) và kiểm tra qua biểu đồ mẫu. Ví dụ, vẽ vài spread mẫu, xác nhận không có bước nhảy kỳ lạ. Sau đó mới áp dụng test trên toàn bộ cặp.

Quy trình hợp lý là: bắt đầu với bộ lọc **tối thiểu** (loại giá 0, sai format, NA rõ ràng) rồi nếu test cho kết quả bất thường (ví dụ residual có mô hình kỳ lạ), hãy xem lại và tăng cường lọc (ví dụ drop outlier trong chuỗi mức giá). Điều này đảm bảo ta không loại bỏ quá nhiều dữ liệu quan trọng ngay lần đầu.

Kết luận: đề xuất quy trình và checklist trước khi test

Dưới đây là các kết luận thực dụng để nộp vào notebook:

- **Quy trình đề xuất (data-cleaning workflow):** (1) Load dữ liệu phút cho mỗi tài sản. (2) Chuẩn hóa timestamp (chuyển về cùng múi giờ, loại bỏ ngày nghỉ). (3) Định nghĩa khung thời gian chung: tạo chỉ số thời gian đều mỗi phút trong ngày giao dịch chung và dùng forward/back-fill để lấp missing giá trước đó ³ ⁷. (4) Kiểm tra và loại bỏ các giá bất thường: giá ≤ 0 , NA, nhảy quá mức (outlier) hoặc thanh khoản thấp trầm trọng. (5) Xác định cơ sở dữ liệu cuối cùng cho 500 tài sản – loại bỏ những tài sản thiếu dữ liệu nghiêm trọng. (6) Với mỗi cặp, join hai chuỗi theo timestamp chung (inner join) trước khi chạy Engle-Granger.
- **Ghi chú quyết định: raw price vs log price:** Nên ưu tiên sử dụng **log(price)** khi test cointegration, vì việc này chuyển vấn đề về tỉ lệ giá (suitable cho một số quan sát tài chính) và giúp ổn định phương sai. Nhiều tài liệu về pairs trading sử dụng log price. Nếu test cho thấy chuỗi log-giá đều có đơn vị dừng, thì mô hình cointegration trở nên tuyến tính hơn và residual mang ý nghĩa log-spread. Chỉ dùng giá thô nếu có lý do đặc biệt (ví dụ mình quan tâm đến chênh lệch tuyệt đối rất nhỏ và giá đã tương đối ổn định).
- **Checklist tiền test cho dữ liệu minute-level:**
 - ✓ Sắp xếp index theo thời gian và loại bỏ ngoại lệ (giá ≤ 0 , NA rõ).
 - ✓ Đảm bảo khung giờ đồng bộ: chỉ xem xét giờ thị trường cả hai cùng mở và sử dụng forward-fill/backward-fill cho data ngắn.
 - ✓ Loại bỏ tài sản thiếu dữ liệu nhiều hoặc dao động cực thấp/đặc biệt.
 - ✓ Kiểm tra seasonality: xác định vùng mở/móng cửa, nghỉ giữa phiên và đảm bảo mô hình đã loại bỏ hiệu ứng đó nếu cần.
 - ✓ Lựa chọn log transform: nếu dùng log, áp dụng trước khi align.
 - ✓ Cuối cùng vẽ thử các spread mẫu và kiểm tra thủ công vài trường hợp bất thường.

Các bước và checklist này giúp bảo đảm dữ liệu sạch, ít nhiễu khi chạy phương pháp Engle-Granger và ADF, qua đó tăng độ tin cậy của báo cáo pairs.

Nguồn tham khảo: Các nghiên cứu về dữ liệu cao tần ³ ¹ ² và các bài hướng dẫn xử lý dữ liệu tài chính ¹ ⁷.

¹ ⁴ ⁷ Handling Missing Data in Trading Datasets – Blog

<https://bluechippalgorithms.com/blog/handling-missing-data-in-trading-datasets/>

² ³ Major Issues in High-Frequency Financial Data Analysis: A Survey of Solutions

<https://www.mdpi.com/2227-7390/13/3/347>

5 6 Working with High-Frequency Tick Data – Cleaning the Data - QuantPedia
<https://quantpedia.com/working-with-high-frequency-tick-data-cleaning-the-data/>